01 / ЗАДАЧА

Куда пойдём сегодня?

Диалог превращает пожелания в подбор мест — с источниками, погодой и маршрутом.

DayOut AI agent

Веб-прототип

Москва · свидания · прогулки · кафе · культурный досуг



СХЕМАТИЧНАЯ ИЛЛЮСТРАЦИЯ

Не десять вкладок. Один связный разговор.

Для кого

Для человека, который выбирает досуг в Москве и уточняет пожелания по ходу разговора.

«Хочу на свидание, тихое место на юге Москвы. Нас двое, бюджет 3000 ₽».

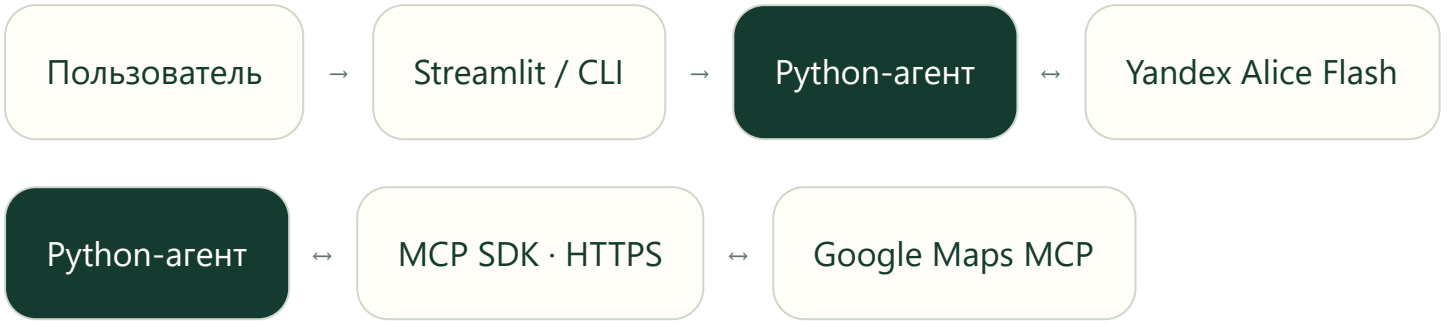
Найти кандидатов → сохранить условия → уточнить район или формат.

Граница MVP

- Подбор мест и диалог с уточнениями.
- Погода и пешие маршруты по запросу.
- Ссылки на источники и обозначение неизвестного.
- Без бронирования, оплаты и постоянной истории.
- Цена и «тихая атмосфера» не гарантируются без данных.

03 / АРХИТЕКТУРА

Модель решает.
Python исполняет и проверяет.



На стороне приложения

Память сеанса, план запроса, JSON Schema, лимиты шагов, проверка ссылок и контролируемая обработка ошибок.

На стороне сервисов

LLM выбирает действия и составляет текст. Официальный Maps Grounding Lite возвращает геоданные и атрибуцию.

Пять инструментов. Разные типы задач.

compute_routes

Расстояние и длительность пути между двумя точками. Для пешего сценария нужен WALK.

`origin, destination, travelMode`

> MCP — протокол взаимодействия. Достоверность текста и соответствие условиям требуют отдельных проверок.

05 / AI-ЛОГИКА

Условия живут дольше одной реплики.

01

План

JSON: намерение, город, район, цель, бюджет, нужные инструменты.

02

Действие

LLM выбирает вызов. Python проверяет имя, схему и аргументы.

03

Данные

Результат MCP возвращается модели с источниками.

04

Ответ

Проверка ссылок, неизвестности и явных противоречий.

Бюджет — условие, не обещание цены.

Сумма, единица и число людей сохраняются. Отсутствие цен не превращается в гарантию.

Смена района — новое действие.

Старые карточки не доказывают наличие подходящих мест в новой области.

06 / МЕТОДИКА EVAL

Вызвать инструмент ≠ правильно решить задачу.

30
основных сценариев

20 / 10
настройка / итоговая часть

5
типов инструментов

15
ходов в плане стресс-теста

Автоматические проверки

Завершение, нужные и запрещённые вызовы, дата и час погоды, аргументы, сохранение ограничений, отсутствие лишних источников.

Оценка содержания

LLM-рецензент сравнивает ответы с исходными данными MCP. Отдельно — выборочная сверка. Оценка той же моделью имеет риск смещения.

В отчётах сохраняются агрегаты и категории ошибок. Сырые ответы Maps не записываются в датасет.

07 / ИЗМЕРЕНИЯ

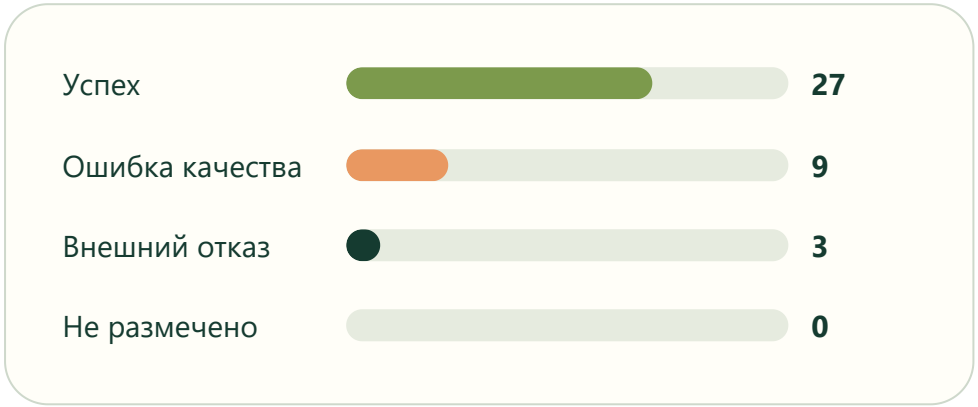
Результат — в числах, ошибки — отдельно.

39
сценарных попыток

87%
техническое завершение

69%
сквозной успех по критериям

15.4 с
медиана времени хода



39 из 90 попыток выполнены

27 прошли все критерии; 9 ошибок качества и 3 внешних отказа. Остальные 51 отложены: исчерпана дневная квота Google Maps Demo Key.

Данные: 30.10.2026 · r6. LLM-assisted review той же моделью; полного человеческого аудита нет.

То, что обнаружили на реальных сценариях.

▼ **Открытые ошибки: поиск и длинный диалог**

Модель иногда пропускает обязательный поиск; строгая близость к метро не прошла. Стресс-тест не завершил 15 ходов. Эти задачи не объявлены исправленными.

▶ **Повторяющиеся ID инструментов**

▶ **Неизвестная цена и бюджет**

▶ **Погода и лишний параметр**

▶ **География и соответствие ссылок**

▶ **Внешние сервисы и память**

09 / ВОСПРОИЗВОДИМОСТЬ

Один репозиторий.
Один опубликованный сервис.

Запуск и хостинг

```
pip install -r requirements.txt
streamlit run app.py

# Технические проверки
python -m pytest -q
```

Streamlit Community Cloud · конфигурация через Secrets · ключи не входят в репозиторий.

Открыть сервис ↗

Калькулятор одного диалога

Входные токены: 5000

Выходные токены: 1000

0,70 ₽

Оценка по 0,1 ₽ / 1000 входных и 0,2 ₽ / 1000 выходных токенов Alice Flash. Без скидки за кэш и токены инструментов; не счёт провайдера.

Основной частичный Eval: около 36.95 ₽, включая LLM-разметку.

От вопроса — к проверяемому ответу.

① «Подбери два музея Москвы для человека, которому интересна история города».

② «Теперь выбери один из найденных, используя только полученные данные».

③ «Проверь погоду в Москве на завтра. Нужен прогноз на день».

Живое демо ↗ **Репозиторий ↗** **Методика Eval ↗**

Перед демо проверить квоту Maps и разбудить Streamlit. При отказе показать причину и фактические результаты, без имитации успешного поиска.