01 / ЗАДАЧА

Куда пойдём сегодня?

Диалог превращает пожелания в подбор мест — с источниками, погодой и маршрутом.

DayOut AI agent

Веб-прототип

Москва · свидания · прогулки · кафе · культурный досуг



СХЕМАТИЧНАЯ ИЛЛЮСТРАЦИЯ

Не десять вкладок. Один связный разговор.

Для кого

Для человека, который выбирает досуг в Москве и уточняет пожелания по ходу разговора.

«Хочу на свидание, тихое место на юге Москвы. Нас двое, бюджет 3000 ₽».

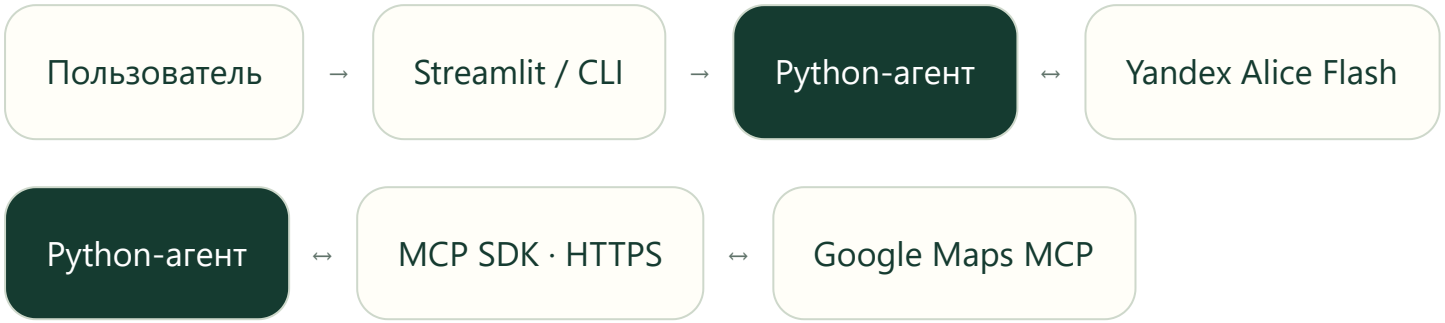
Найти кандидатов → сохранить условия → уточнить район или формат.

Граница MVP

- Подбор мест и диалог с уточнениями.
- Погода и пешие маршруты по запросу.
- Ссылки на источники и обозначение неизвестного.
- Без бронирования, оплаты и постоянной истории.
- Цена и «тихая атмосфера» не гарантируются без данных.

03 / АРХИТЕКТУРА

Модель решает.
Python исполняет и проверяет.



На стороне приложения

Память разговора, JSON Schema, исполнение инструментов, лимиты шагов, проверка ссылок и обработка ошибок.

На стороне сервисов

LLM выбирает действия и составляет текст. Официальный Google Maps MCP возвращает сведения о местах, погоде, маршрутах и ссылки на источники.

Пять инструментов. Разные типы задач.

compute_routes

Расстояние и длительность пути между двумя точками. Для пешего сценария нужен WALK.

`origin, destination, travelMode`

> MCP — протокол взаимодействия. Достоверность текста и соответствие условиям требуют отдельных проверок.

05 / ОТ СООБЩЕНИЯ К РЕЗУЛЬТАТУ

Как агент понимает запрос и выполняет уточнения.

01

Понять

Прочитать диалог и выбрать следующий шаг.

02

Найти

Вызвать инструмент и вернуть данные модели.

03

Проверить

Сохранить условия и проверить готовый ответ.

04

Объяснить

Дать варианты со ссылками и указать, что неизвестно.

Первый запрос

«Найди два кафе в центре Москвы.
Нас двое, бюджет 3000 ₽».

Агент ищет кафе и сохраняет условия разговора.

Уточнение

«Лучше в Нагатино».

Агент ищет кафе в новом районе. Москва, двое участников и бюджет 3000 ₽ сохраняются.

06 / МЕТОДИКА ОЦЕНКИ

Проверка на запросах, которые задаёт пользователь.

30
основных сценариев

37
реплик в основном наборе

5
видов инструментов

15
реплик в длинном диалоге

Работает ли цепочка?

Получен ли ответ? Вызван ли нужный инструмент? Совпадает ли дата прогноза? Сохранился ли бюджет после уточнения?

Полезен ли ответ?

Подходят ли варианты задаче? Подтверждены ли описания данными Maps? Есть ли ссылки и честное предупреждение о неизвестных ценах?

> Технические условия проверяет программа. Содержание оценивает отдельный запрос к Alice Flash. Оценка той же моделью может ошибаться; независимая экспертная разметка не проводилась.

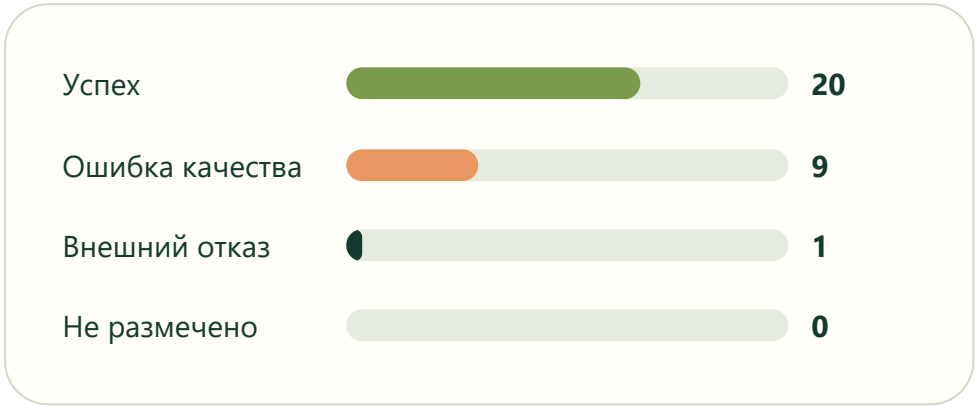
Результаты проверки на реальных запросах.

30
сценарных попыток

97%
все ответы получены

67%
ответы прошли все критерии

16.9 с
медиана времени хода



Основной набор r10: 30 сценариев

r10: 20/30 сценариев прошли все критерии. Целевая проверка прямого цикла r18: 3/6; контролируемая близость: 0/2. Отдельный длинный диалог: 13/15 ответов с реальными API; остановка из-за таймаута Яндекса. Все попытки сохранены в отчёте.

Полный набор — r10; исправления проверены отдельно. Оценка содержания — модельная, не экспертная.

Что подтверждено данными, а что нужно уточнить.

▼ Бюджет: сумма известна, полный чек — не всегда

Агент сохраняет, например, 3000 ₽ на двоих. В ответе Maps часто нет актуальных цен меню или билетов. Такие места предлагаются как кандидаты: гарантировать итоговую стоимость нельзя.

▼ «Рядом» проверяется по пешему маршруту

Небольшое расстояние на карте не означает короткий путь пешком. По умолчанию 15 минут — ориентир: если подходящего места нет, можно искать чуть дальше и явно назвать время пути. Строгий предел пользователя сохраняется.

▼ «Красивое» и «романтичное» — предпочтения пользователя

Агент объясняет выбор по доступному описанию, но не гарантирует атмосферу, отсутствие шума или свободные столики.

▼ Источник должен подтверждать конкретное утверждение

Ссылка на ресторан подтверждает, о каком месте идёт речь. Она не позволяет придумывать цены, часы работы или блюда, которых нет в полученных данных.

▼ Приложение зависит от внешних сервисов

При сетевой ошибке, исчерпании квоты или отсутствии прогноза пользователь получает сообщение о проблеме. Недоступные сведения не заменяются выдуманным ответом.

09 / ВОСПРОИЗВОДИМОСТЬ

Один репозиторий.
Один опубликованный сервис.

Запуск и хостинг

```
pip install -r requirements.txt
streamlit run app.py

# Технические проверки
pip install -r requirements-dev.txt
python -m pytest -q
```

Streamlit Community Cloud · конфигурация через Secrets · ключи не входят в репозиторий.

Открыть сервис ↗

Калькулятор одного диалога

Входные токены: 10000

Выходные токены: 1000

1,20 ₽

Оценка по 0,1 ₽ / 1000 входных и 0,2 ₽ / 1000 выходных токенов Alice Flash. Без скидки за кэш и токены инструментов; не счёт провайдера.

Основной набор: около 30,97 ₽ по известным токенам. Часть usage отсутствует; это не счёт провайдера.

От вопроса — к проверяемому ответу.

① «Подбери два музея Москвы для человека, которому интересна история города».

② «Теперь выбери один из найденных, используя только полученные данные».

③ «Проверь погоду в Москве на завтра. Нужен прогноз на день».

Живое демо ↗ **Репозиторий ↗** **Методика Eval ↗**

Рекомендации сопровождаются источниками. В деталях запроса видны использованные инструменты и время ответа.